

Informe Técnico - Taller Final

Estadística y Análisis Exploratorio de Datos

Dataset: Heart Disease - Cleveland Clinic Foundation (UCI)

Especialización en Programación para Ciencia de Datos

Facultad de Ingeniería - Universidad Pedagógica y Tecnológica de Colombia

Estudiantes: Arley Rativa, Andrea Nova

Notebook adjunto: Taller_Final_Heart_Disease_COLAB.ipynb

1. Resumen ejecutivo

Se analizó el dataset Heart Disease del UCI Machine Learning Repository, que recopila información clínica de 303 pacientes evaluados en la Cleveland Clinic Foundation. Cada paciente está descrito por 13 variables predictoras (demográficas, hemodinámicas, bioquímicas y electrocardiográficas) y un diagnóstico anatomopatológico de enfermedad coronaria. Para el taller, la variable diagnóstica original núm. (0 a 4) se binarizó en disease (0 = sano, 1 = enfermo, presencia de cualquier grado de obstrucción). En la muestra hay 139 pacientes enfermos (45.9%) y 164 sanos (54.1%). Solo dos columnas (ca y thal) presentan valores faltantes (4 y 2 NaN respectivamente, < 1.5%), no hay registros duplicados.

El informe documenta el análisis exploratorio descriptivo, el ajuste de distribuciones de probabilidad por máxima verosimilitud, la inferencia estadística respondiendo las siete preguntas de investigación, y la construcción de un pipeline reproducible de preprocesamiento sin data leakage. Los tres hallazgos principales son:

- **Hallazgo 1.** Colesterol total NO permite por sí solo discriminar enfermedad coronaria: la diferencia de medias entre enfermos y sanos es 8.83 mg/dl con IC95% [-2.82, 20.48] (cruza el cero) y d de Cohen = 0.171 (efecto pequeño). El IC al 95% del colesterol medio poblacional cae en [240.8, 252.5] mg/dl.
- **Hallazgo 2.** Las variables funcionales y anatómicas son las que más señal aportan: ca (vasos coronarios afectados, r de Pearson = 0.46 con disease), oldpeak (depresión ST en esfuerzo, r = 0.43) y thalach (frecuencia cardíaca máxima, r = -0.42). El ANOVA confirma que la frecuencia máxima difiere entre los cuatro tipos de dolor pectoral ($F = 17.41$, $p = 1.9e-10$).
- **Hallazgo 3.** Existe asociación fuerte entre sexo y enfermedad (chi-cuadrada = 22.04, $p = 2.7e-06$, V de Cramer = 0.270). Entre los hombres el 55.3% presentan enfermedad frente al 25.8% en mujeres. La prevalencia global se estima en 45.9% con IC95% Wilson [40.4%, 51.5%].

Recomendación práctica: la detección temprana de cardiopatía coronaria en esta población exige combinar marcadores anatómicos (ca, thal) y funcionales (oldpeak, thalach, cp) y considerar el sexo como factor de estratificación; el colesterol total aislado no es una bandera roja suficiente.

2. Descripción del dataset y EDA

2.1 Variables y diagnóstico inicial

El dataset original cuenta con 14 variables (13 predictoras + num, más la binaria derivada disease) y 303 observaciones. No hay duplicados ($R["duplicados"] = 0$). Los valores faltantes son escasos: 4 en ca y 2 en thal, codificados originalmente como "?". La proporción de NaN (1.32% y 0.66%) permite imputarlos sin riesgo de sesgo significativo.

Tabla 1. Clasificación estadística de las 14 variables analizadas.

Variable	Tipo estadístico	Escala	Descripción
age	continua	razón	Edad en años (29-77)
sex	nominal binaria	nominal	0=mujer, 1=hombre
cp	nominal	nominal	Tipo de dolor pectoral (1-4)
trestbps	continua	razón	Presión arterial reposo
chol	continua	razón	Colesterol sérico mg/dl
fbs	nominal binaria	nominal	Azúcar ayunas > 120 mg/dl
restecg	nominal	nominal	ECG en reposo
thalach	continua	razón	Frecuencia cardiaca máxima
exang	nominal binaria	nominal	Angina inducida ejercicio
oldpeak	continua	razón	Depresión ST
slope	ordinal	ordinal	Pendiente del segmento ST
ca	discreta/ordinal	razón	Vasos coloreados (0-3)
thal	nominal	nominal	Resultado thalassemia
disease	nominal binaria	nominal	Objetivo binario derivado de núm.

2.2 Estadísticos descriptivos

Los estadísticos descriptivos para las variables numéricas (media, mediana, desviación estándar, coeficiente de variación, asimetría y curtosis) se resumen en la Tabla 2.

Tabla 2. Resumen de estadísticos descriptivos para variables numéricas.

Variable	Media	Mediana	DE	CV %	Asimetría	Curtosis
age	54.44	56.00	9.04	16.6	-0.21	-0.52
trestbps	131.69	130.00	17.60	13.4	0.71	0.88
chol	246.69	241.00	51.78	21.0	1.14	4.49
thalach	149.61	153.00	22.88	15.3	-0.54	-0.05
oldpeak	1.04	0.80	1.16	111.7	1.27	1.58
ca	0.67	0.00	0.94	139.4	1.19	0.26

Lectura clínica:

- age tiene media 54.4 y mediana 56.0 años, distribución casi simétrica (asimetría -0.21) y platicúrtica (curtosis -0.52), típica de una cohorte adulta seleccionada para evaluación cardiovascular.
- chol presenta sesgo a la derecha (1.14) y curtosis alta (4.49) por la presencia de valores extremos como 564 mg/dl. La media 246.7 sugiere hipercolesterolemia límite alta en la cohorte.
- thalach tiene leve sesgo a la izquierda (-0.54) porque los enfermos comprimen la cola inferior con FC máximas reducidas.

- oldpeak y ca tienen CV superiores al 100% por el exceso de ceros en pacientes sanos: la mayoría registra cero depresiones ST y cero vasos afectados.

2.3 Distribuciones univariadas

Los histogramas con KDE y la curva Normal superpuesta (Figura 1) muestran que ninguna variable continua se comporta como una Normal estricta. La depresión ST (oldpeak) es claramente no Normal por el exceso de ceros (33% de la muestra).




Figura 1. Distribucion de colesterol con KDE y curva Normal teórica superpuesta.




Figura 2. Distribucion de frecuencia cardiaca máxima alcanzada (thalach).




Figura 3. Distribucion de oldpeak: marcado exceso de ceros, cola larga a la derecha.

2.4 Análisis bivariado y correlaciones

Los boxplots de las variables continuas por estado de enfermedad (Figura 4) muestran que thalach y oldpeak son los que más diferencian a sanos de enfermos. El pairplot por disease (Figura 5) confirma visualmente que la frontera no es lineal univariada.




Figura 4. Boxplot de thalach por estado de enfermedad. Los enfermos alcanzan FC máximas notablemente menores.




Figura 5. Boxplot de oldpeak por estado de enfermedad. Mayor depresión ST en enfermos.

Pairplot por estado de enfermedad




Figura 6. Pairplot de variables continuas coloreado por disease (verde=sano, rojo=enfermo).

Las matrices de correlación (Figura 7) y la Tabla 3 reportan las tres correlaciones lineales y monotónicas más fuertes con disease.




Figura 7. Matriz de correlación de Pearson (lineal) entre variables numéricas y disease.

Tabla 3. Top-3 correlaciones por método. Pearson y Spearman coinciden en identificar a ca, oldpeak y thalach como las principales senales.

Método	Variable 1	Variable 2	Correlación
Pearson	ca	disease	+0.460
Pearson	oldpeak	disease	+0.425
Pearson	thalach	disease	-0.417
Spearman	ca	disease	+0.489
Spearman	thalach	oldpeak	-0.432
Spearman	thalach	disease	-0.423

Coincidencia Pearson vs Spearman: los tres pares dominantes incluyen los mismos involucrados con **disease**, lo que indica relaciones monotónicas robustas a outliers. Las pequeñas diferencias en magnitud (Spearman algo mayor que Pearson en ca-disease) sugieren ligera no-linealidad capturada mejor por la correlación de rangos.

3. Distribuciones de probabilidad y ajuste MLE

3.1 Ajuste Normal por máxima verosimilitud

Tabla 4. Estimadores MLE Normales y pruebas formales de normalidad.

Variable	mu MLE	sigma MLE	KS	KS p	Shapiro	Shapiro p	Conclusión
age	54.439	9.024	0.0771	0.0518	0.9865	0.0061	Normalidad rechazada o dudosa
thalach	149.607	22.837	0.0723	0.0803	0.9765	0.0001	Normalidad rechazada o dudosa
chol	246.693	51.691	0.0554	0.3000	0.9473	0.0000	Normalidad rechazada o dudosa

Solo el KS sobre chol da $p > 0.05$ (0.30); Shapiro rechaza normalidad en las tres variables. El tamaño muestral ($n=303$) hace que las pruebas detecten desviaciones pequeñas; visualmente las curvas MLE están razonablemente cercanas a la distribución empírica, pero las colas y la curtosis se desvían lo suficiente para invalidar el supuesto estricto.




Figura 8. Ajuste Normal MLE para chol. La curva MLE coincide con la Normal muestral; el ajuste visual es razonable pero Shapiro rechaza ($p < 1e-4$).

3.2 Distribucion no Normal: oldpeak

Sobre los 204 valores positivos de oldpeak (excluyendo los 99 ceros que corresponden a ausencia de depresión ST), se ajustaron distribuciones gamma y exponencial con $floc=0$.

Tabla 5. Comparación de ajuste no Normal para oldpeak (valores positivos).

Distribucion	Log-verosimilitud	AIC	BIC
gamma	-276.83	557.65	564.29
exponencial	-292.63	587.26	590.58

La distribución **gamma** gana con una diferencia de AIC mayor a 29 puntos sobre la exponencial, evidencia muy fuerte según Burnham y Anderson. La gamma admite forma con moda separada del origen, consistente con la cola observada.




Figura 9. Histograma de oldpeak con ajustes gamma (rojo) y exponencial (gris). Gamma reproduce mejor la forma con moda alejada del origen.

3.3 Gaussiana multivariada y condicional

Sobre el par (age, thalach) se estimaron por MLE $\mu_{\hat{}} = (54.44, 149.61)$ y la matriz de covarianzas. Las elipses de 50%, 90% y 95% (Figura 10) encierran las regiones de mayor probabilidad. La distribución condicional thalach | age = 55 es Normal con media **149.05** y DE **21.03** lpm.




Figura 10. Gaussiana bivariada (age, thalach) con elipses de confianza al 50/90/95% y pacientes coloreados por estado de enfermedad.

Interpretación clínica: un paciente de 55 años tendría una FC máxima esperada de aprox. 149 lpm bajo este modelo; el rango de ± 1 sigma cubre [128, 170] lpm. La regla clínica 220 - edad estimaría 165 lpm a esa edad; la cohorte observada está por debajo, coherente con selección por sospecha de enfermedad cardiovascular.

3.4 Bayes simple para fbs

Con prior Beta (2, 5) y datos ($y = 45$, $n = 303$), la posterior es Beta (47, 263) con media **0.1516** vs MLE = 0.1485. Con $n = 303$ los datos dominan el prior débil, las dos estimaciones convergen.




Figura 11. Prior, likelihood y posterior para la proporción de pacientes con $fbs=1$.

4. Resultados de inferencia estadística

A continuación, se responde a las siete preguntas de investigación. La Tabla 6 condensa estadístico, p-valor, intervalos de confianza y conclusión explícita. Las subsecciones expanden cada caso.

Tabla 6. Resumen consolidado de las pruebas de inferencia (preguntas 17 a 23).

#	Análisis	Estadístico	p-valor	IC inf	IC sup	Conclusión
17	IC 90% colesterol promedio	246.6931	-	241.7854	251.6008	Con 90% de confianza, el colesterol medio poblacional esta entre 241.79 y 251.60 mg/dl.
17	IC 95% colesterol promedio	246.6931	-	240.8397	252.5465	Con 95% de confianza, el colesterol medio poblacional esta entre 240.84 y 252.55 mg/dl.
17	IC 99% colesterol promedio	246.6931	-	238.9825	254.4036	Con 99% de confianza, el colesterol medio poblacional esta entre 238.98 y 254.40 mg/dl.
18	IC 95% varianza thalach	523.2658	6.996e-05	448.8945	617.8875	Con 95% de confianza la varianza de thalach está entre 448.9 y 617.9 (DE entre 21.2 y 24.9 lpm). Nota: Shapiro rechaza normalidad (p=0.000), el IC chi-cuadrada es referencial.
19	Welch t-test: chol enfermos > sanos (unilateral)	1.4924	0.06832	-2.8150	20.4842	No se rechaza H0 al 5%: no hay evidencia de que el colesterol medio de los enfermos sea mayor (diferencia=8.83 mg/dl, IC95% [-2.82, 20.48], d de Cohen clásica (pooled SD)=0.171, efecto despreciable a pequeño).
20	ANOVA un factor: thalach por cp	17.4131	1.907e-10	-	-	Se rechaza H0 al 5% (F=17.41, p=1.907e-10): la frecuencia cardiaca máxima media difiere entre los 4 tipos de dolor pectoral. Tukey identifica los pares que difieren (ver tabla anexa). Supuestos violados (normalidad por grupo OK=False, homocedasticidad OK=True); como respaldo no paramétrico, Kruskal-Wallis H=47.32, p=2.979e-10 confirma la conclusión del ANOVA.
21	Chi-cuadrada sex vs disease	22.0426	2.667e-06	-	-	Se rechaza H0 al 5% (chi2=22.04, p=2.667e-06): existe asociación entre sexo y enfermedad. V de Cramer=0.270 (asociación pequeña).
22	KS: age ~ N(54, 9)	0.0959	0.007068	-	-	Se rechaza H0 al 5%: la edad no se ajusta a Normal (54, 9) (KS=0.096, p=0.007).
23	Proporción enfermedad - IC Wald 95%	0.4587	-	0.4026	0.5149	IC Wald 95%: [0.4026, 0.5149].
23	Proporción enfermedad - IC Wilson 95%	0.4587	-	0.4035	0.5150	IC Wilson 95%: [0.4035, 0.5150]. Ambos IC casi coinciden porque n=303 y p~0.46 lejos de los extremos.

4.1 Pregunta 17 - IC del colesterol promedio

Con $n = 303$, media muestral = 246.69 mg/dl y DE = 51.78, los intervalos de confianza t para el colesterol promedio poblacional son:

- 90%: [241.79, 251.60] mg/dl
- 95%: [240.84, 252.55] mg/dl
- 99%: [238.98, 254.40] mg/dl

Se usa la distribución t de Student porque σ poblacional es desconocida. Aunque Shapiro rechaza normalidad estricta, con $n = 303$ el teorema central del límite hace que la distribución de la media muestral sea aproximadamente Normal, validando el IC. El QQ-plot (no mostrado en este resumen) presenta desviaciones leves en las colas.

4.2 Pregunta 18 - IC de la varianza de thalach

La varianza muestral de thalach es 523.27 (DE = 22.88 lpm). El IC chi-cuadrada al 95% para la varianza poblacional es [448.89, 617.89] (DE entre 21.19 y 24.86 lpm). El supuesto de normalidad es necesario para la validez exacta del IC, y Shapiro lo rechaza ($p = 6.996e-05$), por lo que el intervalo se reporta como **referencial** más que estricto. Una alternativa robusta sería un IC bootstrap.

4.3 Pregunta 19 - Welch para chol enfermos vs sanos

Test de Welch (unilateral, $H_1: \mu_{enf} > \mu_{sano}$). La diferencia de medias observada es 8.83 mg/dl ($enf = 251.47$, $sanos = 242.64$). El estadístico Welch $t = 1.492$ con df aproximado = 298.6 arroja p unilateral = 0.0683. El IC al 95% para la diferencia es [-2.82, 20.48] **e incluye el cero**.

Verificación de homocedasticidad (Levene): $p = 0.7032 > 0.05$, no se rechaza homocedasticidad.

Elección coherente del tamaño de efecto: al no rechazarse la igualdad de varianzas, se reporta la d de Cohen clásica con DE pooled = 0.171. Como verificación, la d con DE promedio (no-pooled) y la d de Glass (DE del grupo sano) son 0.172 y 0.165, todas en el mismo orden de magnitud (efecto pequeño según los umbrales de Cohen 0.2/0.5/0.8).

****Conclusión 19:** No se rechaza H_0 al 5%. El colesterol total no muestra evidencia suficiente de ser mayor en los enfermos en esta cohorte, en línea con la literatura clínica que sitúa al colesterol como factor de riesgo modesto frente a marcadores funcionales y anatómicos.

4.4 Pregunta 20 - ANOVA thalach por tipo de dolor pectoral

ANOVA de un factor para thalach según cp. Antes del ANOVA se verificaron los supuestos:

- Normalidad por grupo (Shapiro): cp = 1, $p = 0.463$, cp = 2, $p = 0.052$, cp = 3, $p = 0.001$, cp = 4, $p = 0.209$
- Homocedasticidad (Levene entre los 4 grupos): $p = 0.0621$ (OK).

En el grupo cp = 3 Shapiro arroja $p = 0.001$ (normalidad violada). Por precaución se complementa con la alternativa no paramétrica Kruskal-Wallis: $H = 47.32$, $p = 2.979e-10$.

ANOVA resultante: $F = 17.41$, $p = 1.907e-10$. Se rechaza H_0 con altísima confianza. Kruskal-Wallis confirma la conclusión (mismo sentido del rechazo), por lo que la inferencia no depende del supuesto de normalidad.

Tabla 7. Media de thalach por tipo de dolor pectoral.

cp	Significado	n	Media thalach
1	Angina típica	23	155.96
2	Angina atípica	50	162.42
3	Dolor no anginoso	86	155.41
4	Asintomático	144	140.68




Figura 12. Boxplot de thalach por tipo de dolor pectoral. cp=4 (asintomático) presenta la media más baja (140.7 lpm), consistente con peor capacidad cronotrópica.

Lectura del Tukey HSD (anexo Excel hoja tukey_thalach_cp): los pares que difieren significativamente son los que involucran $cp = 4$ (asintomático) frente a 1, 2 y 3. Esto es clínicamente interesante porque los pacientes asintomáticos en esta cohorte tienen una FC máxima reducida, posiblemente por enfermedad silente avanzada.

4.5 Pregunta 21 - Chi-cuadrada sexo vs enfermedad

Tabla 8. Tabla de contingencia sex vs disease (frecuencias absolutas).

sex	sano	enfermo
0 (mujer)	72	25
1 (hombre)	92	114

Test de independencia: $\chi^2 = 22.04$, $gl = 1$, $p = 2.667e-06$. Se rechaza la hipótesis de independencia. El tamaño de efecto V de Cramer = 0.270 (asociación pequeña según los criterios de Cohen para tablas 2x2). En términos absolutos los hombres tienen tasa de enfermedad de $114/206 = 55.3\%$ frente a $25/97 = 25.8\%$ en mujeres: el riesgo relativo es 2.14, una asociación clínicamente relevante a pesar del V pequeño.

4.6 Pregunta 22 - KS edad vs Normal (54, 9)

Kolmogórov-Smirnov compara la edad empírica con $N(54, 9)$: $D = 0.0959$, $p = 0.0071$. Como $p < 0.05$, **se rechaza H_0 **: la edad no es exactamente Normal (54, 9). El QQ-plot (Figura 14) confirma desviaciones moderadas en las colas; la distribución empírica es algo más platicúrtica que la Normal teórica.




Figura 13. QQ-plot de age frente a $N(54, 9)$. Desviaciones moderadas en las colas.

Tanto la prueba formal como el QQ-plot llevan a la misma conclusión (divergencia, aunque modesta). La prueba KS es estricta con $n = 303$: incluso desviaciones pequeñas alcanzan significación estadística.

4.7 Pregunta 23 - IC para la proporción de enfermedad

Estimador puntual: $\hat{p} = 139/303 = 0.4587$.

- IC Wald 95%: [0.4026, 0.5149].
- IC Wilson 95%: [0.4035, 0.5150].

Ambos intervalos son prácticamente idénticos porque $n = 303$ es grande y $\hat{p} \sim 0.46$ está lejos de los extremos 0 y 1. Wald y Wilson difieren notablemente solo cuando n es pequeño o $\hat{p}$ se acerca a 0 o 1; en tal caso Wilson conserva mejor cobertura nominal.

Recomendación: en general usar Wilson por robustez.

5. Pipeline de preprocesamiento

5.1 Tratamiento de outliers

Tabla 9. Conteo de outliers univariados por IQR y Z-score.

Variable	Outliers IQR	Outliers Z-score ($ z >3$)
age	0	0
trestbps	9	2
chol	5	4
thalach	1	1
oldpeak	5	2

Isolation Forest con contaminación 5% detecta 16 observaciones atípicas multivariadas.

Decisión: NO se eliminan automáticamente. Los valores extremos en chol (hasta 564 mg/dl), trestbps (>180 mm Hg) y oldpeak (>4) son clínicamente plausibles en pacientes con enfermedad coronaria severa o comorbilidades. Eliminarlos sesgaría la señal y perdería información del grupo enfermo. Los outliers se documentan; si en una etapa de modelado posterior se identifica que distorsionan un modelo lineal sensible, se podría aplicar minorizado.

5.2 Imputación de valores faltantes (ca y thal)

Tabla 10. Comparación de tres estrategias de imputación para ca y thal.

Columna	# NaN	Media (mediana)	Media (KNN)	Media (Iterativa)
ca	4	0.6634	0.6845	0.6727
thal	2	4.7228	4.7333	4.7319

Los tres métodos producen medias casi idénticas (diferencias < 0.03), porque solo hay 6 NaN en total (4 en ca, 2 en thal).

Decisión: **SimpleImputer** con la mediana para columnas numéricas/discretas y la moda para categóricas. Razones: simplicidad, transparencia, reproducibilidad y que con tan pocos faltantes los métodos sofisticados no aportan ventaja.

5.3 Codificación de variables categóricas

Se aplican las técnicas especificadas literalmente por la rúbrica (punto 26) y las variables adicionales del dataset se justifican aparte:

Tabla 11. Codificación final de variables categóricas alineada a la rúbrica.

Variable	Técnica	Justificación
sex	Label Encoding	Binaria 0/1, ya numérica. Label Encoding = passthrough.
exang	Label Encoding	Binaria 0/1, idem.
cp	One-Hot	Nominal sin orden (1=típica, 2=atípica, 3=no anginoso, 4=asintomático).
restecg	One-Hot	Nominal sin orden (0/1/2).
slope	Ordinal Encoding	Orden clínico 1<2<3 (ascendente, plana, descendente).
fbs	Passthrough (binaria)	No incluida en rubrica p.26. Binaria 0/1, equivalente a Label.
thal	One-Hot	No incluida en rubrica p.26. Nominal (3/6/7), sin orden natural.
ca	MinMax	Discreta 0-3, se trata como cuantitativa ordinal y se escala.

5.4 Escalamiento y comparación MinMax vs StandardScaler

Las variables continuas (age, trestbps, chol, thalach, oldpeak) se normalizan con MinMaxScaler al rango [0, 1]. Esta elección es preferible porque algunas variables (como oldpeak) son fuertemente no-normales con fronteras conocidas y MinMax preserva la forma de la distribución. StandardScaler centra y escala por DE pero asume distribuciones aproximadamente Normales para que las distancias z sean interpretables; en presencia de skew alto y outliers, MinMax es más estable. La Figura 15 compara ambas estrategias para chol.




Figura 14. Comparación del escalamiento de chol: original, MinMax [0,1] y StandardScaler (z-score). MinMax conserva la forma; z-score recentra, pero amplifica colas.

5.5 Pipeline final con scikit-learn y diagrama de flujo

El pipeline combina un ColumnTransformer (que aplica imputación + escalado / codificación por bloque de columnas) con un wrapper Pipeline. El ajuste se realiza únicamente sobre el conjunto de entrenamiento (fit en X_train) y se transforma el de prueba con los parámetros aprendidos en train, evitando cualquier filtración de información del test.




Figura 15. Diagrama de flujo del pipeline de preprocesamiento sin data leakage.

5.6 Verificación train/test

Tabla 12. Coherencia de estadísticos entre train y test (split 80/20 estratificado).

Variable	Media full	Media train	Media test	DE full	DE train	DE test
age	54.44	54.55	54.00	9.04	9.00	9.27
trestbps	131.69	130.96	134.59	17.60	17.62	17.35
chol	246.69	249.84	234.21	51.78	52.85	45.58
thalach	149.61	149.96	148.20	22.88	22.69	23.75
oldpeak	1.04	1.00	1.20	1.16	1.12	1.30

Train transformado: 242 filas x 20 columnas; test transformado: 61 x 20. Después del pipeline no quedan NaN (train: 0, test: 0). Las diferencias de media entre train y test son menores al 6% en todas las variables; la mayor (chol: 249.8 vs 234.2) refleja variabilidad muestral aceptable con $n = 303$.

6. Conclusiones y recomendaciones

6.1 Lo que aprendimos del dataset

La cohorte de 303 pacientes Cleveland esta enriquecida en casos sospechosos: 45.9% presenta enfermedad coronaria, lejos del 6-10% esperable en población general. Esto es coherente con que provenga de un servicio de cardiología.

El colesterol total tiene poder discriminante limitado en este dataset (Welch p_one = 0.068, d de Cohen = 0.171). Esto NO contradice la evidencia epidemiológica sobre dislipidemia y riesgo cardiovascular, sino que refleja que en una población ya seleccionada para evaluación los marcadores funcionales son más informativos que los bioquímicos.

Las señales más fuertes para predecir disease son anatómicas y funcionales: Ca (numero de vasos coloreados por fluoroscopia), thalach (reserva cronotrópica) y oldpeak (depresión ST inducida por esfuerzo). El tipo de dolor pectoral cp añade información clínica: el grupo asintomático (cp=4) tiene la FC máxima más baja y mayor prevalencia de enfermedad.

4. ****Sexo es un factor de estratificación relevante**** (V de Cramer = 0.270, p = 2.7e-6). La tasa de enfermedad es del 55.3% en hombres y 25.8% en mujeres en esta cohorte.

6.2 Variables más relevantes para predecir enfermedad

Sobre la base del análisis bivariado, las correlaciones y los efectos detectados en inferencia, las variables con mayor capacidad discriminante son, en orden aproximado:

- ca - numero de vasos coronarios afectados (r = +0.46 con disease).
- thal - resultado de la prueba thalassemia.
- oldpeak - depresión ST en esfuerzo (r = +0.43).
- thalach - frecuencia cardiaca máxima (r = -0.42).
- cp - tipo de dolor pectoral (ANOVA F=17.4 p=1.9e-10 frente a thalach).
- exang - angina inducida por ejercicio.
- sex - factor de riesgo categórico (V de Cramer = 0.27).

6.3 Limitaciones

- Tamaño muestral moderado (n = 303), limita la potencia para detectar efectos pequeños como el del colesterol y dificulta validación cruzada robusta para modelos complejos.
- Cohorte histórica (Cleveland Clinic, 1988) y posiblemente no representativa de poblaciones contemporáneas o de otras regiones.
- Variables categóricas codificadas con esquemas clínicos específicos (p.ej. cp 1-4, thal 3/6/7) que no necesariamente trasladan a otros sistemas de salud.
- Faltantes en ca y thal: pocos, pero relevantes en el grupo enfermo donde estos marcadores son críticos.
- No-normalidad de las variables continuas, lo que limita el uso directo de pruebas paramétricas estrictas (Welch, ANOVA, IC chi-cuadrada de varianza); en este informe se complementaron con alternativas no paramétricas (Kruskal-Wallis) y se enfatizan los intervalos de confianza.

6.4 Siguiente paso recomendado

1. Modelado supervisado: entrenar una regresión logística regularizada (L1/L2) y un modelo basado en arboles (Random Forest o gradient boosting) sobre el pipeline construido. Comparar AUC-ROC, sensibilidad y especificidad con validación cruzada estratificada de 5 pliegues.
2. Calibración y umbral clínico: ajustar el umbral de decisión a la priorización de sensibilidad sobre especificidad propia del cribado cardiovascular (perdernos un enfermo es más costoso que un falso positivo).
3. Interpretabilidad: reportar coeficientes (o SHAP values) para que la salida del modelo sea entendida por el clínico; las variables más predictoras deben coincidir con las identificadas aquí.
4. Validación externa: replicar el pipeline en otra cohorte UCI (Hungary, Switzerland, Long Beach) para evaluar generalización.

Anexos

- Taller_Final_Heart_Disease_COLAB.ipynb - notebook reproducible
- resultados_taller_heart_disease.xlsx - libro con todas las tablas (diccionario, descriptivos, normalidad, inferencia, Tukey, outliers, imputación, verificación train/test).
- resultados_inferencia.csv - tabla resumen Pregunta 17-23.
- tukey_thalach_cp.csv - tabla Tukey HSD para cp.
- verificacion_train_test.csv - estadísticos antes/después del pipeline.
- figuras taller/ - 38 PNG a 160 dpi (histogramas, boxplots, heatmaps, pairplot, gaussiana bivariada, condicional, bayes, QQ-plots, ANOVA, escaladores, diagrama de pipeline).