

Proyecto No. 2. Consultoría de Datos Empresariales
Estadística y Análisis Exploratorio de Datos
Especialización en Programación para Ciencia de Datos
UPTC

Instrucciones

- Grupos de dos personas.
- Exposición Sábado 23 de mayo de 2026

Contexto Empresarial

Ustedes acaban de ser contratados como equipo de Data Science junior en DataVenture Analytics, una firma de consultoría de datos con clientes en distintos sectores. Su primera asignación es real: un cliente ha solicitado apoyo para entender mejor sus datos y tomar decisiones basadas en evidencia.

La firma entre el siguiente memorando interno:

MEMORANDO INTERNO — DataVenture Analytics

Para: Equipo de Data Science Asignado

Asunto: Encargo de análisis exploratorio y estadístico para cliente externo

Prioridad: Alta — Entrega: 23 mayo 2026

Descripción del encargo:

Nuestro cliente opera en un sector que genera datos continuamente pero no cuenta con capacidad interna para analizarlos de forma sistemática. Nos ha solicitado un informe técnico que responda tres preguntas clave:

¿Cómo se comportan las principales variables del negocio? (distribución, tendencia central, variabilidad)

¿Qué patrones o relaciones relevantes se pueden identificar visualmente?

¿Puede el equipo construir un modelo probabilístico simple que actualice creencias a medida que llegan más datos? (enfoque bayesiano)

Nota: El equipo debe seleccionar un dataset público relevante al sector que elija, proponer el enfoque de análisis y ejecutarlo completo en R. El informe final debe ser legible tanto para el equipo técnico como para la gerencia del cliente.

1. Como data scientists, su trabajo no es solo “correr código”. Deben:

- Elegir y justificar un dataset relevante para una pregunta de negocio real.
- Proponer un plan de análisis antes de ejecutarlo.
- Interpretar cada resultado en términos del negocio, no solo en términos estadísticos.

- Presentar hallazgos con claridad: tablas, gráficas y texto narrativo que cuente una historia.
- Concluir con recomendaciones accionables para el cliente.

Nota: Consejo profesional: los mejores informes de data science no son los que tienen más código, sino los que conectan los números con decisiones concretas. Piensen siempre: ¿quién leerá esto y qué decisión tomará con base en sus hallazgos?

Propuesta Técnica del Equipo

2. Antes de comenzar el análisis, el equipo debe redactar una propuesta técnica breve (máximo 1 página en el informe) que responda lo siguiente. Esta sección simula la etapa de “scopping” que todo proyecto de data science real requiere.

El equipo debe elegir libremente un dataset de fuentes públicas.

3. En el informe, incluya una ficha técnica del dataset con:

- Nombre y URL exacta de descarga.
- Número de filas y columnas.
- Período o año de los datos.
- Sector o dominio (salud, finanzas, transporte, etc.).
- Pregunta de negocio que el equipo propone responder con estos datos.

4. Construya en el informe una tabla clasificando todas las variables del dataset. Para cada variable indique:

Variable	Tipo	Escala de medición	Relevancia para el negocio
----------	------	--------------------	----------------------------

5. Responda brevemente (3-4 oraciones por punto):

- Si tuvieran que recolectar estos datos desde cero, ¿qué tipo de muestreo probabilístico usarían: aleatorio simple, sistemático, estratificado o por conglomerados? Justifique con base en las características del fenómeno.
- El dataset disponible, ¿es una muestra o una población? ¿Qué tan representativa considera que es? Argumente.
- Identifiquen al menos un posible sesgo de selección presente en el dataset y cómo podría afectar las conclusiones.

En el script R incluya el siguiente bloque (adapte los nombres de columnas a su dataset real):

```
# =====
# PARTE 1: Carga y clasificación de variables
# =====

library(readr)      # leer CSV
library(dplyr)      # manipulación de datos
library(skimr)      # resumen rápido
```

```
# Cargue el dataset
datos <- read_csv("mi_dataset.csv")

# Vista general
glimpse(datos)
skim(datos)          # dimensiones, NAs, distribución rápida

# Conteo de valores faltantes por variable
colSums(is.na(datos))

# Tabla de clasificación manual (ajuste según su dataset)
clasificacion <- data.frame(
  Variable = names(datos),
  Tipo     = c("continua", "discreta", "nominal", "ordinal"), # ajustar
  Escala   = c("razón", "razón", "nominal", "ordinal"),      # ajustar
  stringsAsFactors = FALSE
)
print(clasificacion)
```

6. Para las 3–5 variables numéricas más importantes, calcule e interprete en el informe:

- Media, mediana y moda (¿coinciden? ¿qué dice eso sobre la distribución?).
- Desviación estándar, varianza y rango intercuartílico (IQR).
- Coeficiente de asimetría (skewness) y curtosis. ¿La distribución es simétrica? ¿Tiene colas pesadas?
- Identifique al menos 1 variable que se aproxime a una distribución teórica conocida (normal, exponencial, Poisson...) y argumente por qué.

Nota: Recuerde: no basta con reportar números. Para cada estadístico, escriba 1–2 oraciones explicando qué significa ese valor para el negocio del cliente.

7. Seleccione una variable binaria o categórica (por ejemplo: “éxito / fracaso”, “churn sí / no”, “calidad alta / baja”) y:

- Calcule probabilidades simples, condicionales y conjuntas relevantes para el negocio.
- Calcule la función de distribución acumulada (FDA) de al menos 1 variable cuantitativa.
- Calcule $E[X]$ (esperanza) e interprételo: ¿qué valor “esperaría” la empresa en promedio?

```
# =====
# PARTE 2: Estadísticas descriptivas y distribuciones
# =====

library(moments)      # skewness y kurtosis
library(fitdistrplus) # ajuste de distribuciones

# Estadísticas básicas
var_objetivo <- datos$mi_variable # reemplace por su variable

cat('Media:      ', mean(var_objetivo, na.rm = TRUE), '\n')
cat('Mediana:    ', median(var_objetivo, na.rm = TRUE), '\n')
cat('SD:         ', sd(var_objetivo, na.rm = TRUE), '\n')
cat('IQR:        ', IQR(var_objetivo, na.rm = TRUE), '\n')
cat('Skewness:    ', skewness(var_objetivo, na.rm = TRUE), '\n')
```

```
cat('Kurtosis: ', kurtosis(var_objetivo, na.rm = TRUE), '\n')

# Resumen completo
summary(var_objetivo)

# Ajuste a distribución teórica (ejemplo: normal)
fit_norm <- fitdist(var_objetivo[!is.na(var_objetivo)], "norm")
summary(fit_norm)
plot(fit_norm)

# FDA empírica
plot(ecdf(var_objetivo), main = 'FDA empírica', col = 'navy')

# Probabilidades condicionales (tabla de contingencia)
tabla <- table(datos$var_cat_1, datos$var_cat_2) # ajustar
prop.table(tabla) # probabilidades conjuntas
prop.table(tabla, margin = 1) # condicional por fila
```

8. El grupo debe producir y comentar las siguientes 5 gráficas en el informe:

#	Gráfica	Variable(s)	¿Cuándo y por qué usarla?
1	Histograma + densidad (KDE)	1 variable cuantitativa continua	Muestra la forma de la distribución, asimetría y posibles modas. Imprescindible como primer paso.
2	Boxplot por categoría	1 cuantitativa + 1 categórica	Compara distribuciones y detecta outliers entre grupos. Útil para preguntas tipo “¿diferencia entre segmentos?”
3	Gráfica de barras	1 cualitativa (nominal u ordinal)	Muestra frecuencias o proporciones. Ideal para variables con pocas categorías significativas.
4	Scatter plot (dispersión)	2 cuantitativas continuas	Explora relación o correlación. El primer paso antes de una regresión.
5	Gráfica libre a elección	Libre (el equipo justifica)	El equipo elige el tipo más apropiado para un patrón de interés en su dataset.

Cada gráfica en el informe debe cumplir:

- Título informativo.
- Etiquetas en los ejes con unidades cuando aplique.
- Párrafo de interpretación: ¿qué le dice esta gráfica al cliente? ¿qué decisión podría tomar con base en ella?

```
# =====
# PARTE 3: Visualización exploratoria con ggplot2
# =====

library(ggplot2)
library(dplyr)

# Tema personalizado para todas las gráficas
mi_tema <- theme_minimal() +
  theme(plot.title = element_text(face='bold', color='#1F3864', size=13),
        axis.title = element_text(size=11),
        panel.grid = element_line(color='#EEEEEE'))

# Gráfica 1: Histograma + KDE
```

```
ggplot(datos, aes(x = mi_variable)) +
  geom_histogram(aes(y = after_stat(density)),
    bins = 30, fill = '#1F3864', alpha = 0.7) +
  geom_density(color = '#FFC000', linewidth = 1.2) +
  labs(title = 'Distribución de [variable]', x = '[variable]', y = 'Densidad')
+
  mi_tema

# Gráfica 2: Boxplot por categoría
ggplot(datos, aes(x = reorder(var_cat, var_num, median),
  y = var_num, fill = var_cat)) +
  geom_boxplot(alpha = 0.8, outlier.color = 'red', outlier.size = 2) +
  coord_flip() +
  labs(title = 'Distribución de [variable] por [categoría]') +
  mi_tema + theme(legend.position = 'none')

# Gráfica 3: Barras
datos %>%
  count(var_cat) %>%
  mutate(prop = n / sum(n)) %>%
  ggplot(aes(x = reorder(var_cat, -prop), y = prop)) +
  geom_col(fill = '#1F3864') +
  scale_y_continuous(labels = scales::percent) +
  labs(title = 'Proporción por [categoría]', x = '', y = '') +
  mi_tema

# Gráfica 4: Scatter plot
ggplot(datos, aes(x = var_x, y = var_y)) +
  geom_point(alpha = 0.5, color = '#1F3864') +
  geom_smooth(method = 'lm', color = '#FFC000', se = TRUE) +
  labs(title = 'Relación entre [X] y [Y]', x = '[X]', y = '[Y]') +
  mi_tema
```

Contexto: El cliente quiere saber cuál es la probabilidad de que un evento de interés ocurra (por ejemplo: una venta exitosa, un cliente fiel, un fallo, etc.). Al principio tiene creencias previas basadas en experiencia; ustedes las formalizan y las actualizan con los datos.

9. El equipo debe definir en el informe:

- Parámetro de interés θ : la proporción (probabilidad) de que el evento de interés ocurra en su dataset.
- Distribución a priori $\text{Beta}(\alpha, \beta)$: elijan valores que reflejen la creencia inicial del cliente. Justifiquen su elección. (¿El cliente cree que el evento es raro, común o no tiene idea?)
- Evidencia: cuántos éxitos (k) y fracasos ($n - k$) observan en los datos.
- Distribución a posteriori $\text{Beta}(\alpha + k, \beta + n - k)$: acótela y grafique ambas distribuciones.

10. Traduzca los resultados al lenguaje del cliente. Por ejemplo:

- "Antes de ver los datos, el cliente creía que la tasa de conversión era alrededor del 20%. Después de analizar 300 transacciones (72 exitosas), la estimación actualizada es 24.1% (IC 90%: 19.8% – 28.6%)."
- Compare la media a priori vs. a posteriori: ¿los datos modificaron significativamente la creencia inicial?
- Calcule un intervalo de credibilidad al 90%: ¿en qué rango está el 90% de la probabilidad posterior?

```
# =====  
# PARTE 4: Inferencia Bayesiana (Beta-Binomial)  
# =====  
  
library(ggplot2)  
  
# --- 1. Definir parámetros ---  
# Evento de interés: (defina cuál es en un comentario)  
alpha_prior <- 3      # creencia previa de éxitos  
beta_prior  <- 7      # creencia previa de fracasos  
  
# Evidencia de los datos  
k <- sum(datos$evento == 1, na.rm = TRUE) # éxitos observados  
n <- sum(!is.na(datos$evento))           # total de observaciones  
cat('Exitos:', k, '/ Total:', n, '/ Proporción:', round(k/n, 3), '\n')  
  
# --- 2. Distribución a posteriori ---  
alpha_post <- alpha_prior + k  
beta_post  <- beta_prior  + (n - k)  
  
cat('A priori:      Beta(', alpha_prior, ', ', beta_prior, ')\n')  
cat('A posteriori: Beta(', alpha_post, ', ', beta_post, ')\n')  
cat('Media a priori:      ', round(alpha_prior/(alpha_prior+beta_prior), 3),  
    '\n')  
cat('Media a posteriori:', round(alpha_post/(alpha_post+beta_post), 3), '\n')  
  
# --- 3. Intervalo de credibilidad 90% ---  
ic_90 <- qbeta(c(0.05, 0.95), alpha_post, beta_post)  
cat('IC 90%: [', round(ic_90[1],3), ', ', round(ic_90[2],3), ']\n')  
  
# --- 4. Gráfica: a priori vs a posteriori ---  
theta <- seq(0, 1, length.out = 500)  
df_plot <- data.frame(  
  theta = rep(theta, 2),  
  densidad = c(dbeta(theta, alpha_prior, beta_prior),  
               dbeta(theta, alpha_post, beta_post)),  
  distribucion = rep(c('A priori', 'A posteriori'), each = 500)  
)  
  
ggplot(df_plot, aes(x = theta, y = densidad, color = distribucion,  
                    linetype = distribucion)) +  
  geom_line(linewidth = 1.4) +  
  scale_color_manual(values = c('A priori' = '#888888', 'A posteriori' =  
  '#1F3864')) +  
  geom_vline(xintercept = alpha_post/(alpha_post+beta_post),  
            color = '#FFC000', linetype = 'dashed', linewidth = 1) +  
  labs(title = 'Actualización bayesiana: a priori vs a posteriori',  
       subtitle = paste0('IC 90%: [', round(ic_90[1],3), ', ',  
       round(ic_90[2],3), ']',  
       x = expression(theta), y = 'Densidad', color = '', linetype = '') +  
  theme_minimal() +  
  theme(legend.position = 'top', plot.title = element_text(face='bold',  
    color='#1F3864'))
```

11. Presente los 3–5 hallazgos más importantes en lenguaje no técnico. Cada hallazgo debe:

- Referenciar el resultado estadístico o visual que lo soporta.

- Expresarse en términos del negocio (no “la curtosis es 4.2” sino “la variable tiene valores extremos frecuentes que podrían representar pérdidas atípicas”).

12. Con base en el análisis, proponga al menos 3 acciones concretas que el cliente podría tomar. Cada recomendación debe:

- Ser específica y factible.
- Estar respaldada por al menos un resultado del análisis.
- Indicar qué datos adicionales serían útiles para refinar la recomendación.

13. Todo buen informe reconoce sus limitaciones. Mencione al menos 2:

- Limitaciones del dataset (tamaño, posibles sesgos, datos faltantes, etc.).
- Supuestos que hicieron durante el análisis que podrían no cumplirse en la realidad.

Nota: Recuerde: un cliente prefiere un analista honesto sobre las limitaciones de sus datos a uno que vende certezas que los datos no garantizan. La credibilidad técnica se construye con transparencia sobre los supuestos y la incertidumbre.